# Análise e Modelagem de Preços de Carros Usados

Gustavo Almeida Silva

Universidade Federal de Juiz de Fora

07/07/2023

### O Mercado de Carros Usados

- Acessibilidade
- Sustentabilidade


### Dados Utilizados


### 12 variáveis e 1000 observações


- v.id
- road\_old
- road\_now
- years
- km
- rating
- condition
- economy
- top\_speed
- hp
- torque
- current\_price

# Separação e Análise Exploratória dos Dados

- Divisão Treino e Teste (0.75, 0.25)
- Ausência de Valores Faltantes








### Modelos


- Saturado
- Correlacional

	Saturado	Correlacional
(Intercept)	-14651.9*	20605.4*
	p = <0.1	p = <0.1
road_now	0.5***	0.5***
	p = <0.1	p = <0.1
road_old	0.5***	0.5***
	p = <0.1	p = <0.1
years	-1595.4***	-1063.3**
	p = <0.1	p = <0.1
km	-4.0***	-4.0***
	p = <0.1	p = <0.1
rating	285.8	
	p = 0.2	
condition	4629.4***	
	p = <0.1	
economy	41.7	
	p = 0.8	

Num.Obs.	748	748
R2	0.995	0.985
R2 Adj.	0.995	0.984
AIC	15720.9	16585.0
BIC	15776.3	16612.7
Log.Lik.	-7848.427	-8286.511
RMSE	8722.06	15666.58

### Residuos






Teste	Modelo.Sat.P.valor	Modelo.Corr.P.valor
Shapiro	0	0
Cramer	0	0
Lilliefors	0	0

- Rejeição da Hipótese de Normalidade
- Heterogeneidade da Variância


# Engenharia de Características

- Criação de novas variáveis via transformação
- Tentativa de melhorar o modelo




### Transformações utilizadas

- % Perda de Valor =  $\frac{(ValorInicial-ValorAtual)\times 100}{ValorInicial}$
- ullet Deterioração do Veículo = Media(condition, years, km)
- Potencia do Motor =  $Media(top\ speed^2,\ hp^5,\ torque)$




• Modelo:  $current\_price = \beta_0 + \beta_1 \ value\_loss\_pct + \beta_2 \ deterioration + \beta_3 \ engine\_power + E$ 


	Features
(Intercept)	739155.0***
	p = <0.1
value_loss_pct	-771.7***
	p = <0.1
deterioration	-12.3***
	p = <0.1
engine_power	0.0
	p = 0.1
Num.Obs.	748
R2	0.880
R2 Adj.	0.879
AIC	18115.6
BIC	18138.7
Log.Lik.	-9052.782
RMSE	43639.20




Teste	Modelo.Feat.P.valor
Shapiro	0.2048031
Cramer	0.3276374
Lilliefors	0.4188786



# Análise de Diagnósticos







# Multicolinearidade VIF\_Values value\_loss\_pct 1.000291 deterioration 1.008633 engine\_power 1.008797

# Regularização


- Busca penalizar variávies colineares
- Modelo n\u00e3o apresenta multicolinearidade, e portanto n\u00e3o espera-se melhora
- K-fold e Leave One Out para robuste de métricas
- Lasso (L1)
- Ridge (L2)
- Elastic Net (Mistura 0.7 de penalty L1 e 0.3 de Penalty L2)

### Lasso Tuning






#### **Elastic Net Tuning**



## Tópico extra

- Assuntos Comentados em Aula
- Modelo Bayesiano (família Gaussina sem fixação de hiperparâmetros)
- Aprendizado de Máquina (Random Forest sem tuning de hiperparâmetros)
- K-fold e Leave One Out para robuste de métricas



- Métricas iguais e piores do que o modelo linear simples
- Complexidade de Interpretação

# Validação

• Melhor Modelo:  $current\_price = \beta_0 + \beta_1 \ value\_loss\_pct + \beta_2 \ deterioration + \beta_3 \ engine\_power + E$ 

	Features
(Intercept)	739155.0***
	p = <0.1
value_loss_pct	-771.7***
	p = <0.1
deterioration	-12.3***
	p = <0.1
engine_power	0.0
	p = 0.1
Num.Obs.	748
R2	0.880
R2 Adj.	0.879
AIC	18115.6
BIC	18138.7
Log.Lik.	-9052.782
RMSE	43639.20

# Validação no Conjunto de Teste

Metric	Data_test	Data_Training
rmse	4.438387e+04	4.363920e+04
rsq	8.773829e-01	8.797584e-01

# Valores Preditos 5e+05 -4e+05 -> 3e+05-2e+05 -1e+05-20 10 ò 30

Χ

### Conclusão

- O trabalho utilizou técnicas de regressão linear, como modelos saturados e correlacionais, engenharia de características, análise de diagnósticos e análise de resíduos
- Os resíduos do modelo não rejeitaram a hipótese de normalidade, o que indica um bom ajuste.
- A engenharia de características permitiu criar um modelo com baixa multicolinearidade, conforme indicado pelos baixos valores de VIF
- A aplicação de regularização (L1, L2 e Elastic Net) não trouxe melhorias significativas ao modelo.
- Comparando com outros modelos, como os Bayesianos e Random Forest, o modelo de regressão linear simples obteve resultados melhores e uma boa capacidade de generalização.